

Yapay Zeka Destekli Ağ Saldırı Tespit Sistemi — Teknik Rapor

Proje: ml-network-ids | Repo: github.com/canci01/ml-network-ids

1. Özet

Bu çalışmada, CICIDS2017 ağ trafiği veri setiyle eğitilmiş, sızıntısız bir deney kurulumuna sahip bir saldırı tespit sistemi geliştirilmiştir. 2.572.527 satırlık temizlenmiş veri üzerinde Lojistik Regresyon, Random Forest ve XGBoost karşılaştırılmış; XGBoost hem en hızlı (59 saniye) hem en yüksek recall'a (%99.94) ulaşan model olmuştur. Aynı model 7 saldırı kategorisiyle çok sınıflı olarak yeniden eğitilmiş, makro F1 skoru 0.940'a ulaşmıştır. Sonuçlar bir Gradio demosunda sunulmuştur.


2. Giriş ve Motivasyon

Geleneksel imza tabanlı saldırı tespit sistemleri sadece bilinen saldırı kalıplarını yakalayabilir. Makine öğrenmesi tabanlı yaklaşımlar ağ akışı istatistiklerinden öğrenerek daha esnek bir tespit sağlayabilir; ancak IDS literatüründe sık karşılaşılan bir sorun, hatalı deney kurulumundan kaynaklanan yapay olarak şişirilmiş başarı skorlarıdır (ör. kimlik sütunlarının sızması). Bu proje, hem güçlü bir sınıflandırma performansı elde etmeyi hem de bu sızıntı risklerini açıkça test edip raporlamayı amaçlar.

3. Veri

CICIDS2017 (Kaggle aynası: chethuhn/network-intrusion-dataset, CC0): 8 günlük gerçekçi trafik, 2.830.743 satır, 78 flow özelliği, BENIGN + 14 saldırı alt türü.

Temizleme: sütun adı boşlukları temizlendi, dtype'lar küçültüldü; Flow Bytes/s ve Flow Packets/s sütunlarındaki Inf (%0.1) ve negatif değerler (113 satır, CICFlowMeter'in bilinen bir üretim hatası) temizlendi; 8 sabit + 1 kopya sütun silindi; tam kopya satırlar (%9.03) atıldı; 14 alt saldırı türü 7 ana kategoriye indirildi. Sonuç: 2.572.527 satır, aşırı dengesiz sınıf dağılımı (BENIGN %83, Infiltration sadece 36 satır).



Şekil 1 — Ham etiket dağılımı (log ölçek)

EDA bulgusu: İlk varsayımımız "SYN Flag Count saldırıda yüksektir" idi; sayısal doğrulamada bu yanlış çıktı (BENIGN %5.5, saldırı %1.2). Gerçek ayırt edici özellikler Average Packet Size, Flow Bytes/s ve Fwd Packets/s oldu — saldırı trafiği çok daha küçük paketlerle, düşük bayt hızında akıyor.

4. Sızıntısız Deney Kurulumu


src/features.py kuralları: (1) kimlik/meta sütunlar özellik olarak kullanılmaz, (2) StandardScaler sadece train verisiyle fit edilir, (3) %70/%15/%15 stratified split, random_state=42. Destination Port'un sızıntı riski özellikle test edilmiş; XGBoost'un toplam öneminin sadece %0.7'sini oluşturduğu (eşik: %30) doğrulanarak güvenle dahil edilmiştir.

5. İkili Sınıflandırma Sonuçları


Model	Accuracy	Precision	Recall	F1	ROC-AUC	Süre
-------	----------	-----------	--------	----	---------	------

Lojistik Regresyon	0.9409	0.7451	0.9769	0.8454	0.9885	377s
Random Forest	0.9985	0.9961	0.9950	0.9956	0.9997	256s
XGBoost	0.9991	0.9949	0.9994	0.9972	1.0000	59s

IDS'te odak metrik recall'dur (kaçırılan saldırı en pahalı hatadır). XGBoost, 63.861 test saldırısından sadece 40'ını kaçırmıştır (recall %99.94) — üç model arasında en iyi sonuç.




Şekil 2 — Confusion matrix karşılaştırması (3 model)



Şekil 3 — Özellik önemi (Random Forest ve XGBoost)

6. Çok Sınıflı Sınıflandırma Sonuçları

XGBoost, 7 kategoriyle yeniden eğitilmiştir. SMOTE sadece train setine ve sadece az örnekli sınıfları (5000'e kadar) hedefleyen kısıtlı bir stratejiyle uygulanmış, makro F1'i 0.9374'ten 0.9398'e çıkarmıştır ve nihai model olarak seçilmiştir. Ağırlıklı F1: 0.999.



Şekil 4 — Çok sınıflı confusion matrix (satir-normalize)

Hata analizi: Farklı saldırı türleri birbiriyle neredeyse hiç karışmıyor — BruteForce, DoS/DDoS ve PortScan diyagonalde tam 1.00. Asıl hata deseni az örnekli sınıfların (Botnet: %11.3, WebAttack: %1.2, Infiltration: 1/5 örnek) BENIGN olarak kaçırılmasıdır — bu, model hatasından çok, bu sınıflardaki eğitim örneği kıtlığının doğal bir sonucudur.

7. Sonuç ve Gelecek Çalışmalar

XGBoost hem hız hem recall açısından en güvenilir seçim olarak öne çıkmıştır. Sızıntı kontrolü (Destination Port testi) modelin gerçek trafik örüntülerine dayandığını, ezber yapmadığını göstermektedir.

Sınırlılıklar: CICIDS2017 laboratuvar ortamında üretilmiştir, gerçek ağ trafiğinin çeşitliliğini tam yansıtmayabilir; kavram kayması test edilmemiştir; gerçek zamanlı akış işleme kapsam dışıdır; aşırı az örnekli sınıflar (Infiltration) için güvenilir genelleme değerlendirmesi yapılamamaktadır.

Gelecek çalışmalar: (1) UNSW-NB15 ile çapraz veri seti doğrulaması (planlanmış, zaman kısıtı nedeniyle bu sürümde yapılmamıştır), (2) SHAP ile daha derin açıklanabilirlik analizi, (3) gerçek zamanlı akış entegrasyonu.